



UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS CRATEÚS
CIÊNCIA DOS DADOS

Antonio Everton Coelho Teixeira - 540649

Lívian Torres Mariano - 509939

Maria Michelly Lima Alves - 537613

João Victor de Oliveira Rodrigues - 509975

Análise Exploratória de Dados e Visualização de Dados

Crateús - CE

2025

1. Introdução

Este relatório apresenta os resultados da Análise Exploratória de Dados (EDA) realizada sobre um conjunto de dados clínicos e demográficos de 100.000 pacientes. O foco principal foi identificar correlações entre indicadores de saúde (como níveis de glicose e HbA1c), hábitos de vida (sono) e fatores demográficos (idade, gênero) com o risco e o estágio de diabetes. O trabalho envolveu limpeza de dados, análise estatística descritiva e a criação de visualizações para responder a perguntas de negócio específicas.

2. Objetivo

O objetivo principal deste projeto foi explorar o conjunto de dados para compreender padrões, relações e fatores de risco presentes na população analisada.

3. Dados Utilizados

Fonte: [Diabetes Health Indicators Dataset \(Kaggle\)](#).

Dimensão: Aproximadamente 100.000 amostras e 31 features (características), incluindo variáveis clínicas (hba1c, glucose_fasting, bmi), demográficas (age, gender) e scores calculados (diabetes_risk_score).

Processamento: Os dados passaram por etapas de verificação de consistência, tratadas nos notebooks dataset_diabetes.ipynb.

Licença de Uso: O conjunto de dados é disponibilizado sob a licença CC0: Public Domain (Domínio Público). Isso permite o uso livre para fins educacionais, de pesquisa e desenvolvimento de modelos sem restrições de direitos autorais.


Questões Éticas e Privacidade: Não existem questões éticas ou de privacidade associadas ao uso destes dados, pois, todos os dados são gerados usando distribuições estatísticas inspiradas em pesquisas médicas do mundo real, garantindo a preservação da privacidade e, ao mesmo tempo, refletindo padrões de saúde realistas, segundo a Kaggle.

4. Principais Achados

A análise revelou padrões claros que corroboram a literatura médica e trouxeram insights quantitativos sobre a amostra. Abaixo estão os destaques visuais:

4.1. Forte Correlação Clínica (HbA1c vs. Glicose)


Observou-se uma correlação linear positiva muito forte entre os níveis de Hemoglobina Glicada (HbA1c) e a Glicose em Jejum. Pacientes com níveis elevados de uma variável invariavelmente apresentam elevação na outra, sendo estes os principais preditores clínicos para o diagnóstico.



(Figura: Dispersão mostrando a correlação direta entre os níveis de HbA1c e Glicose.)

4.2. O Fator Idade no Agravamento da Doença


A distribuição de idade varia significativamente entre os estágios da doença. Nota-se que os estágios mais avançados de diabetes ou riscos elevados estão concentrados em faixas etárias superiores, indicando que o envelhecimento é um fator de risco crítico e progressivo.



(Figura: Gráfico de densidade (KDE) comparando a distribuição de idade para diferentes diagnósticos.)

4.3. Perfil de Risco Combinado (Idade e Gênero)


A visualização por contagem de pacientes mostra uma predominância de diagnósticos positivos (barras laranja) sobre os negativos (barras azuis) em todas as categorias. O grupo feminino lidera o ranking de casos confirmados com mais de 30 mil pacientes, destacando-se como o cluster demográfico de maior impacto numérico na base de dados analisada.



(Figura: Contagem de casos de diabetes por gênero.)

4.4. Risco por Faixa Etária

Confirmando a análise de distribuição, a visualização direta do risco médio por faixa etária mostra uma tendência ascendente clara. Isso valida a qualidade dos dados, pois reflete o comportamento biológico esperado da doença tipo 2.



(Figura: Tendência de aumento do risco conforme a progressão da faixa etária.)

5. Limitações e Recomendações

Limitações

Origem dos Dados: Sendo um dataset público, as conclusões clínicas devem ser validadas com dados reais hospitalares antes de aplicação prática.

Variáveis Omitidas: Fatores genéticos detalhados ou histórico familiar específico podem estar sub-representados ou simplificados no cálculo do diabetes_risk_score.

Recomendações

Segmentação de Pacientes: Utilizar o *Heatmap* de Idade/Gênero para direcionar campanhas de saúde preventiva focadas nos grupos de maior risco médio.

Monitoramento Combinado: Dado a correlação linear quase perfeita entre HbA1c e Glicose, recomenda-se o uso conjunto de ambas as métricas para evitar falsos negativos em diagnósticos na margem entre saudável e pré-diabético, onde o médico pode requerer o exame de Glicose em Jejum (Glicose no momento) e de Hemoglobina Glicada (Média do açúcar no sangue nos últimos 3 meses).

Investigação de Estilo de Vida: Aprofundar a análise sobre a variável de sono, exercícios físicos e tempo de tela, investigando se a má qualidade do sono, tipos de atividades físicas e o tempo de tela é causa, sintoma ou agravante das comorbidades associadas.

6. Desafios e Aprendizados

Durante o desenvolvimento deste trabalho, os principais pontos de destaque foram:

Desafios:

O maior desafio encontrado foi enxergar relações entre os dados, por exemplo, tentávamos identificar alguma relação entre o diagnóstico e variáveis socioeconômicas

como renda ou escolaridade, para verificar se pessoas com maior escolaridade ou renda poderiam apresentar padrões alimentares melhores ou menor risco de diabetes.

Visualização de Grande Volume: Com 100.000 registros, o uso de *scatter plots* simples gerava "overplotting" (sobreposição excessiva). Foi necessário usar gráficos de densidade (KDE/Heatmaps) para enxergar os padrões reais.

Aprendizados:

Domínio do Seaborn: O projeto permitiu aprofundar o conhecimento na biblioteca seaborn para gerar visualizações estatísticas que comunicam muito mais informação que gráficos de barra simples.

Análise exploratória simples: Ao analisar com passos base, como valores nulos ou faltantes, ficou nítido a importância de começar pela base antes de ir para análises mais complexas, esse processo inicial acelerou o entendimento geral da base de dados.

Interpretações de Visualizações: O processo mostrou que gráficos também são feitos para contar histórias e responder perguntas, e até mesmo trazer novas perguntas.